

Rapport de Projet de Fin d'Etudes

Filière : DUT Informatique décisionnelle et statistiques

Année Universitaire : 2024-2025

Sous le thème :

Détection des fraudes dans les transactions bancaires

Réalisé par :

Nouredine Imgharne

Hamza bendiab

Encadré par :

HASSAN FAOUAZI

Soutenu le 16/06/2025 devant la commission d'examen composée de :

Pr

FADIL Youssef

Président

Pr

HAMIM Mohammed

Examineur

Pr

FAOUZI Hassan

Encadrant

Remerciement

Chers professeurs, chers membres de nos familles, chers collègues et amis, C'est avec une profonde émotion et une immense gratitude que nous prenons la plume aujourd'hui pour vous adresser nos plus sincères remerciements. Le chemin parcouru au cours de notre parcours académique a été jalonné de défis, d'apprentissages et de moments inoubliables, et il est indéniable que votre soutien inestimable a été la pierre angulaire de notre réussite.

Votre présence constante, vos encouragements indéfectibles et votre bienveillance ont constitué un pilier sur lequel nous avons pu nous appuyer à chaque étape. Qu'il s'agisse d'une parole réconfortante lors des moments de doute, d'un conseil éclairé face à une difficulté, ou simplement de la certitude de savoir que vous étiez là, chaque geste, chaque attention a contribué à forger notre détermination et à nous pousser vers l'excellence. Vous avez su créer un environnement propice à l'épanouissement intellectuel et personnel, et pour cela, nous vous en sommes éternellement reconnaissants.

Nous tenons à exprimer une gratitude toute particulière à Monsieur **Faouzi Hassan**, notre encadrant de projet de fin d'études. Son rôle a été bien plus que celui d'un simple superviseur ; il a été un véritable mentor, un guide éclairé dont la patience et le dévouement ont été sans limites. Monsieur Hassan a su nous transmettre non seulement des connaissances techniques approfondies, mais aussi une méthodologie rigoureuse et une passion contagieuse pour la recherche et l'innovation. Ses précieux conseils, toujours pertinents et constructifs, ont été une source d'inspiration inépuisable, nous permettant de repousser nos limites, d'explorer de nouvelles pistes et de concrétiser nos idées les plus ambitieuses. Nous mesurons la chance que nous avons eue de bénéficier de son encadrement exceptionnel tout au long de nos études, et son influence restera gravée dans nos esprits comme un facteur déterminant de notre développement.

Enfin, nous souhaitons réitérer nos remerciements les plus chaleureux à chacune et chacun d'entre vous. Votre confiance en nos capacités, votre bienveillance à notre égard et votre contribution, quelle qu'elle soit, ont rendu cette expérience académique non seulement enrichissante sur le plan intellectuel, mais aussi profondément gratifiante sur le plan humain. Sans votre appui collectif, cette aventure n'aurait pas eu la même saveur, ni la même portée. Nous sommes conscients que notre succès est le fruit d'un effort partagé, et nous sommes fiers d'avoir pu compter sur une communauté aussi solidaire et inspirante.

Dédicace

Nous souhaitons dédier ce travail de fin d'études à toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce projet et à notre parcours universitaire.

À nos parents respectifs, pour leur amour inestimable, leur patience, leurs sacrifices et leur soutien indéfectible tout au long de notre vie. Grâce à eux, nous avons pu avancer avec confiance, détermination et sérénité. Ils ont toujours cru en nous, même dans les moments de doute, et leur présence a été notre plus grande source de motivation.

À nos familles, frères, sœurs et proches, qui ont su nous encourager, nous écouter et nous soutenir moralement à chaque étape de ce projet. Leur bienveillance et leurs paroles réconfortantes nous ont apporté la force nécessaire pour aller au bout de ce travail.

À nos enseignants et encadrants, pour la qualité de leur enseignement, leur disponibilité et leurs conseils précieux. Ils nous ont transmis non seulement des connaissances, mais aussi des valeurs de rigueur, de curiosité intellectuelle et de dépassement de soi.

À nos camarades et amis, pour les échanges enrichissants, l'entraide et les moments de partage qui ont marqué notre parcours.

Enfin, à toutes les personnes qui ont cru en nous et nous ont inspirés à donner le meilleur de nous-mêmes. Ce travail est aussi le fruit de votre confiance.

Résumé

Dans un contexte marqué par l'augmentation constante des fraudes bancaires, engendrant chaque année des pertes financières de plusieurs milliards d'hirhams, notre projet s'inscrit comme une solution technologique visant à répondre efficacement à cette problématique. L'objectif principal est de développer un système de détection des fraudes en temps réel, capable de conjuguer précision, rapidité et interprétabilité. Pour y parvenir, nous avons opté pour l'algorithme XGBoost, reconnu pour ses performances élevées, en particulier sur des ensembles de données fortement déséquilibrés comme ceux que l'on retrouve dans le domaine bancaire. Ce modèle présente plusieurs avantages, notamment une gestion native des valeurs manquantes, des mécanismes de régularisation intégrés qui limitent le surapprentissage, ainsi qu'une vitesse d'exécution qui permet un traitement en temps réel.

Le système que nous avons conçu repose sur une architecture web moderne et bien structurée. Le backend est développé avec le micro-framework Flask, qui permet une gestion efficace des requêtes et l'intégration du modèle de prédiction. Le frontend est réalisé à l'aide des technologies HTML5, CSS3 et JavaScript, offrant à l'utilisateur une interface intuitive et ergonomique. Le tout suit une organisation fondée sur le modèle MVC, garantissant une séparation claire entre les différentes couches de l'application. Les échanges entre les composants s'effectuent à travers une API RESTful, assurant flexibilité et évolutivité du système.

Les résultats obtenus sont très encourageants, avec un taux de détection des fraudes supérieur à 95 %, tout en maintenant un taux de faux positifs inférieur à 3 %, ce qui réduit significativement les alertes injustifiées et facilite le travail des analystes. En complément, l'interface permet non seulement la visualisation des prédictions en temps réel, mais aussi la compréhension des facteurs de risque associés à chaque transaction grâce à des modules d'explicabilité. Par ailleurs, la sécurité des données a été soigneusement prise en compte à travers l'implémentation d'un système d'authentification robuste et l'usage de protocoles de communication chiffrés, assurant la confidentialité et l'intégrité des informations traitées.

Abstract

In a context marked by the constant rise of banking fraud, which causes financial losses of several billion dirahms each year, our project aims to provide a technological solution to this issue. The main objective is to develop a real-time fraud detection system that combines accuracy, speed, and interpretability. To achieve this, we chose the XGBoost algorithm, known for its high performance, especially on highly imbalanced datasets typically found in the banking sector. This model offers several advantages, including native handling of missing values, built-in regularization mechanisms that help prevent overfitting, and fast execution suitable for real-time processing.

The system we designed is based on a modern and well-structured web architecture. The backend is developed using the Flask micro-framework, allowing for efficient request handling and integration of the prediction model. The frontend is built with HTML5, CSS3, and JavaScript, providing users with an intuitive and user-friendly interface. The entire system follows an MVC (Model-View-Controller) architecture, ensuring a clear separation of concerns. Communication between components is handled through a RESTful API, ensuring the system is both flexible and scalable.

The results obtained are very promising, with a fraud detection rate above 95%, while maintaining a false positive rate below 3%, significantly reducing unnecessary alerts and easing analysts' workloads. Additionally, the interface not only enables real-time prediction visualization but also allows users to understand the risk factors associated with each transaction through explainability modules. Furthermore, data security has been carefully addressed through the implementation of a strong authentication system and the use of encrypted communication protocols, ensuring the confidentiality and integrity of all processed information.

TABLE DES MATIERES

Introduction generale.....	12
Chapitre I : L’Etat de l’Art	13
1) Introduction	13
2) détection des fraudes dans les transactions bancaires	13
2.1) Définition	13
3) Étude comparative entre le Machine Learning et le Deep Learning	13
3.1) Deep Learning	13
3.2) Machine Learning	15
3.3) Le choix du machine Learning	15
4) Apprentissage supervisé vs apprentissage non supervisé	16
4.1) L’apprentissage supervise	16
4.2) L’apprentissage non supervisé	17
5) Conclusion	17
Chapitre II : Compréhension de la problématique et des données	18
1) Introduction.....	19
2)Compréhension de la problématique	19
2.1) Objectif métier	19
2.2) Objectif de data mining	20
2.3) Plan préliminaire	20
3) Compréhension des données	20
4) Conclusion	23

Chapitre III : Exploration et Préparation des Donnée	25
1) Introduction	26
2) Exploration des données	26
3) Préparation des données	29
3.1) Nettoyage des données	30
3.2) Rééquilibrage des classes (SMOTE)	31
3.3) Encodage des Variables Catégorielles	32
3.4) Construire des données	32
3.5) Standardisation des données	33
3.6) Sélection des features Pertinentes	34
3.7) Extraction des caractéristiques avec l'ACP	35
3.6.1) Processus de l'ACP	36
3.6.2) Résultats expérimentaux	37
4) Conclusion	37
Chapitre IV : Modélisation et Expérimentation	38
1) Introduction	39
2) Utilité de la modélisation pour l'identification des fraudes	39
3) Choix des méthodes de modélisation	40
3.1) Raisons du Choix Initial des Algorithmes	40
3.1.1) Random Forest	40
3.1.2) Réseaux de Neurones Artificiels (ANN)	41
3.1.3) XGBoost (Extreme Gradient Boosting)	41
3.2) Résultat des modèles Initial	41
3.3) Analyse Comparative entre les modèles	42

3.3.1) Analyse Comparative	42
3.3.2) Importance des Métriques en Détection de Fraude :	43
3.3.3) Choix du modèle final :	43
4) Architecture et fonctionnement du modèle XGBoost	44
4.1) Introduction	44
4.1.1) Principe de base du Gradient Boosting.....	44
4.1.2) Fonctionnement général	45
4.1.3) Avantages du Gradient Boosting.....	45
4.1.4) Limites :	45
4.2) Architecture interne de XGBoost	45
4.2.1) Fonction objectif de XGBoost :	46
4.2.2) Construction des arbres :	46
4.2.3) Calcul du gain avec gradient et hessien	46
5) Gestion des données déséquilibrées et paramètres de XGBoost	47
5.1) Gestion des données déséquilibrées	47
5.2) Paramètres principaux du modèle XGBoost	48
6) Tuning des hyperparamètres avec Grid Search.....	48
6.1) Introduction	48
6.2) Fonctionnement de la Méthode Grid Search :	48
6.3) l'Implémentation de Grid Search:	49
6.4) Performances du Modèle Après Grid Search	50
6.5) interprétation comparative :	50
7) Conclusion	51
Chapitre V : Le Déploiement du Modèle.....	52

1) Introduction.....	53
2) Architecture de déploiement.....	54
2.1) Vue d'ensemble de l'architecture	54
2.2) Choix technologiques	54
2.3) Diagramme d'architecture du système	56
2.4) Conception et Architecture Logicielle	57
2.5) Les interfaces Graphiques de projet	61
3) Conclusion	64
Chapitre VI: Conclusion et perspective	65
Conclusion Générale.....	66
Perspectives	68
Ressources documentaires.....	69

LISTE DES FIGURES

Figure 1 : Deep Learning.....	11
Figure 2 : L'apprentissage supervisé	13
Figure 3 : L'apprentissage non supervisé.....	14
Figure 4 : Les étapes de CRISP-DM.....	16
Figure 5 : Les étapes de construction de notre système	18
Figure 6 : Statistiques descriptives des variables numériques	22
Figure 7 : Répartition des modalités des variables catégorielles	28
Figure 8 : Distribution de la variable cible	28
Figure 9 : Carte de chaleur des corrélations entre les variables	24
Figure 10 : Nuage de points	25
Figure 11 : Distribution des variables numériques	26
Figure 12 : La répartition des valeurs manquantes dans chaque colonne	27
Figure 13 : Conversion des variables	28
Figure 14 : La structure de l'ensemble de données	29
Figure 15 : Standardisation des caractéristiques	30
Figure 16 : Différence entre sélection et extraction	31
Figure 17 : Les caractéristiques extraites	33
Figure 18 : XGBoost résultat	37
Figure 19 : Réseaux de Neurones résultat	38
Figure 20 : Random Forest résultat	38
Figure 21 : La grille de recherche	45
Figure 22 : La meilleure configuration	46
Figure 23 : Après le Grid Search	46
Figure 24 : Avant le Grid Search	46
Figure 25 : Analyse graphique de recall	47
Figure 26 : L'architecture du système	52
Figure 27 : Diagramme de cas d'utilisation (utilisateur)	53
Figure 28 : Diagramme de cas d'utilisation (admin)	54
Figure 29 : Diagramme de composants	55
Figure 30 : Page d'accueil	57
Figure 31 : Page de connexion	57
Figure 32 : page d'inscription	58
Figure 33 : Tableau de bord	59
Figure 34 : Page de prédiction	60
Figure 35 : Page d'historique	61

LISTE DES TABLEAUX

<u>Tableau 1 : Description des Variables de 1 ère catégorie.....</u>	<u>19</u>
<u>Tableau 2 : Description des Variables de 2 ème catégorie.....</u>	<u>19</u>
<u>Tableau 2 : Description des Variables de 3 ème catégorie.....</u>	<u>20</u>
<u>Tableau 2 : Description des Variables de 4 ème catégorie.....</u>	<u>20</u>

LISTE DES ABRÉVIATIONS

Abréviation	Signification complète
IA	Intelligence Artificielle
ML	Machine Learning (Apprentissage automatique)
DL	Deep Learning (Apprentissage profond)
RN / ANN	Réseaux de Neurones / Artificial Neural Network
SMOTE	Synthetic Minority Over-sampling Technique
ACP	Analyse en Composantes Principales
CRISP-DM	Cross-Industry Standard Process for Data Mining
CSV	Comma-Separated Values (valeurs séparées par des virgules)
IQR	Interquartile Range (Écart interquartile)
KNN	K-Nearest Neighbors (k plus proches voisins)
SVM	Support Vector Machine
XGBoost	Extreme Gradient Boosting
AUC	Area Under the Curve (courbe ROC)
RN	Réseau de Neurones
Grid Search	Recherche par grille (optimisation d'hyperparamètres)
HTML	HyperText Markup Language
CSS	Cascading Style Sheets
API	Application Programming Interface
UI	User Interface
HTTP	HyperText Transfer Protocol
IoT	Internet of Things
CPU / GPU	Central / Graphics Processing Unit
K-Means	Algorithme de regroupement (clustering)
DBSCAN	Density-Based Spatial Clustering of Applications with Noise
Pickle	Format de sérialisation Python

INTRODUCTION GENERALE

L'analyse des données de transactions bancaires pour la détection des fraudes est devenue un sujet d'étude d'une pertinence capitale dans les domaines de l'informatique et de l'apprentissage automatique. Ce type de projet offre une opportunité précieuse d'explorer les méthodes avancées de traitement de données, de reconnaissance de motifs et de Machine Learning dans le contexte de l'analyse de flux de données complexes et à fort volume.

Dans le cadre académique, ce projet revêt une importance particulière pour plusieurs raisons. Tout d'abord, il offre aux étudiants l'occasion d'appliquer les connaissances théoriques acquises en classe à un problème concret du monde réel, ayant des implications directes sur la sécurité financière et la protection des consommateurs. Ensuite, il permet de développer des compétences pratiques essentielles en matière de collecte, de prétraitement et d'analyse de données transactionnelles, ainsi qu'en modélisation, en évaluation et en optimisation de modèles de Machine Learning dédiés à la détection d'anomalies. Enfin, ce projet offre une opportunité d'explorer différentes approches et techniques pour résoudre un problème de classification déséquilibré et en constante évolution, ce qui peut élargir la compréhension des étudiants sur les méthodes disponibles, leurs avantages et leurs inconvénients respectifs.

Les objectifs de ce projet académique sont l'acquisition d'une compréhension approfondie du processus de détection des fraudes à partir des données de transactions bancaires, la mise en œuvre de techniques de Machine Learning pour identifier et classer les transactions frauduleuses, et enfin l'évaluation et la comparaison des performances de différentes approches et algorithmes pour l'analyse de données financières. Une attention particulière sera portée à la gestion des faux positifs et des faux négatifs, cruciaux dans ce domaine.

Pour atteindre ces objectifs, nous allons explorer diverses méthodes de prétraitement des données, de création de caractéristiques (feature engineering), de modélisation et d'évaluation des performances. Nous envisageons d'utiliser des techniques de détection d'anomalies et des algorithmes de classification tels que XGBoost, les réseaux de neurones et les forêts aléatoires. Nous utiliserons des outils et des bibliothèques logicielles populaires telles que Python, scikit-learn et Pandas pour la mise en œuvre des différentes étapes du projet.

Chapitre I :

L'Etat

De

L'ART

1. Introduction

Dans cette section, nous passerons en revue les recherches précédentes et les progrès réalisés dans le domaine de la détection des fraudes bancaires à partir de données transactionnelles. L'objectif est de présenter les approches existantes, leurs principes, ainsi que leurs limites, afin de mieux situer notre contribution dans ce contexte.

2. Détection des fraudes dans les transactions bancaires

2.1 Définition

La détection de la fraude est un processus d'identification automatique des activités suspectes ou anormales au sein des données transactionnelles. Elle vise à repérer des comportements frauduleux, tels que des paiements non autorisés, des transferts inhabituels ou des opérations incohérentes par rapport au profil du client. L'objectif est de différencier les transactions légitimes des opérations potentiellement frauduleuses, en s'appuyant sur des techniques d'analyse de données, d'apprentissage automatique ou de détection d'anomalies.

3 Étude comparative entre le Machine Learning et le Deep Learning

3.1 Deep Learning




Figure 1 : Deep Learning

Le Deep Learning (ou apprentissage profond) est une sous-branche de l'apprentissage automatique (Machine Learning) qui repose sur l'utilisation de **réseaux de neurones artificiels profonds**. Il s'agit de modèles composés de plusieurs couches cachées, capables d'apprendre automatiquement des représentations complexes à partir de grandes quantités de données. Grâce à cette structure, le Deep Learning est particulièrement performant pour les tâches comme la reconnaissance d'image, le traitement du langage naturel, ou encore la détection de comportements anormaux dans les données transactionnelles.

3.2 Machine Learning

Le Machine Learning, ou apprentissage automatique, est un domaine de l'intelligence artificielle qui consiste à développer des algorithmes capables d'apprendre à partir de données, sans être explicitement programmés pour chaque tâche. Ces algorithmes analysent les données pour détecter des motifs, faire des prédictions ou prendre des décisions. Le Machine Learning est largement utilisé dans des domaines tels que la détection de fraude, la reconnaissance vocale, ou encore la recommandation de contenu.

3.3 Le choix du machine Learning

Le choix du **Machine Learning** plutôt que du **Deep Learning** dans notre projet peut être justifié par plusieurs facteurs. Tout d'abord, le Machine Learning offre une approche plus simple, plus transparente et plus accessible pour la classification des commentaires en ligne sur les téléphones portables. Contrairement au Deep Learning, qui repose sur des architectures de réseaux neuronaux complexes et nécessite un ajustement précis des hyperparamètres, le Machine Learning permet une mise en œuvre plus directe des algorithmes d'apprentissage automatique.

De plus, les algorithmes de Machine Learning peuvent produire de bons résultats même avec des ensembles de données de taille modérée, ce qui est souvent le cas dans un contexte académique aux ressources limitées. Ils sont également moins sensibles au surapprentissage (overfitting) et présentent une meilleure capacité de généralisation sur de nouvelles données, sans nécessiter une configuration technique poussée. Enfin, le Machine Learning permet une interprétation plus facile des modèles et des résultats obtenus, ce qui est

particulièrement pertinent lorsque la compréhension et l'explication des mécanismes sont prioritaires, comme c'est souvent le cas dans les projets de recherche ou d'étude.

4. L'apprentissage supervisé vs l'apprentissage non supervisé

4.1 L'apprentissage supervise




Figure 2 : L'apprentissage supervise

L'apprentissage automatique est une branche de l'intelligence artificielle qui permet à un système informatique d'**apprendre à partir de données**, sans être explicitement programmé pour chaque tâche. Il repose sur des **algorithmes capables d'identifier des motifs, de faire des prédictions ou de prendre des décisions** en se basant sur l'analyse de données historiques.

L'apprentissage automatique est utilisé dans de nombreux domaines comme la détection de fraude, la reconnaissance faciale, les recommandations de produits, ou encore le traitement automatique du langage

4.2 L'apprentissage non supervisé




Figure 3 : L'apprentissage non supervisé

L'apprentissage non supervisé est un type d'apprentissage automatique dans lequel les algorithmes analysent des données **non étiquetées**, c'est-à-dire sans indication préalable sur les catégories ou résultats attendus. L'objectif est de découvrir des structures cachées, des regroupements (clusters) ou des anomalies dans les données.

Ce type d'apprentissage est particulièrement utile lorsque l'on ne dispose pas de données annotées, ou lorsqu'on cherche à explorer et comprendre les caractéristiques sous-jacentes d'un jeu de données. Parmi les méthodes les plus courantes figurent le **clustering** (ex. : K-Means, DBSCAN) et la détection d'anomalies (ex. : Isolation Forest, Autoencoders).

5. Conclusion

Dans ce chapitre, nous avons présenté les concepts fondamentaux de l'apprentissage supervisé et non supervisé, ainsi que les modèles d'apprentissage automatique tels que **XGBoost** et **Random Forest**. Nous avons également effectué une revue des travaux antérieurs et des avancées majeures dans le domaine, en analysant les différentes approches existantes ainsi que leurs avantages et limites. Cette étude nous a permis de mieux cerner les défis et les opportunités liés à la détection des fraudes dans les transactions bancaires. Le chapitre suivant sera consacré à la description détaillée de la méthodologie employée dans notre étude.

Chapitre II:

Compréhension de la problématique et des données

automatique de ces activités frauduleuses est devenue une nécessité stratégique pour garantir la sécurité des clients et limiter les pertes financières. L'objectif de ce projet est de développer un système capable d'identifier, en temps réel, les transactions potentiellement frauduleuses à partir des données historiques. Afin de permettre à tout utilisateur (qu'il soit une entreprise financière, un développeur indépendant ou une plateforme de paiement) d'envoyer des données transactionnelles et de recevoir en retour une évaluation automatique du risque de fraude.

2.2 Objectif de data mining

Pour atteindre cet Objectif métier, une tâche de **classification supervisée** a été identifiée comme la plus adaptée. Le problème est formulé comme une classification binaire : chaque transaction doit être prédite comme étant frauduleuse ou non. Cette tâche de data mining implique l'utilisation d'algorithmes d'apprentissage automatique capables de différencier les comportements normaux des comportements suspects, en se basant sur des données historiques labellisées.

2.3 Plan préliminaire

Afin d'atteindre les objectifs fixés pour la détection automatique de fraudes dans les transactions bancaires, un plan de projet structuré a été mis en place. Ce plan suit une démarche rigoureuse et séquentielle, représentée dans la **Figure 5**, et se base sur les étapes clés du cycle de vie d'un projet de data science.

3. Compréhension des données

Les données utilisées dans cette étude sont disponibles à l'adresse suivante sur Kaggle <https://www.kaggle.com/code/nkibria115/bank-account-fraud/input> , ces données proviennent de la suite Bank Account Fraud (**BAF**) synthétiques sur la fraude à l'ouverture de compte, comprenant 1 million d'instances et basé sur des données réelles.

Notre base de données est divisée en quatre **catégories** :

- ✓ La première catégorie concerne les informations générales du client, décrivent le profil du demandeur.




Figure 5 : Les étapes de construction de notre système

- ✓ La deuxième catégorie reflète l'activité et les habitudes de demande.
- ✓ La troisième catégorie permet de valider l'identité ou la stabilité financière.
- ✓ La quatrième catégorie concerne les Données techniques, liées à la session ou au device utilisé.

Il y a 7 variables pour décrire le profil du demandeur, Voici la liste de ces variables :

Variable	Description
income	revenu mensuel déclaré.
name_email_similarity	ressemblance entre le nom et l'email (score de 0 à 1).
prev_address_months_count, current_address_months_count	stabilité résidentielle
customer_age	âge du client.
days_since_request	Délai depuis la demande.
intended_balcon_amount	Montant initial transféré pour la demande.

Tableau 1 : Description des Variables de 1 ère catégorie

Avec 9 variables reflètent l'activité et les habitudes de demande :

Variable	Description
payment_type	type de paiement (catégoriel).
zip_count_4w	fréquence du code postal dans les demandes récentes (4 semaines).
velocity_6h, velocity_24h, velocity_4w	nombre d'actions dans les 6h, 24h, et 4 semaines.
bank_branch_count_8w	nombre d'agences visitées en 8 semaines.
date_of_birth_distinct_emails_4w	nombre d'emails distincts pour une même date de naissance en 4 semaines.
employment_status	statut professionnel (code CA, CB, etc.).
credit_risk_score	score de risque de crédit (plus haut = plus fiable).

Tableau 2 : Description des Variables de 2 ème catégorie

Ensuite , 9 variables permettent de valider l'identité ou la stabilité financière :

Variable	Description
email_is_free	1 si email gratuit (Gmail, etc.), 0 sinon.

housing_status	statut du logement (codes internes).
phone_home_valid, phone_mobile_valid	validité des numéros fixe / mobile.
bank_months_count	ancienneté du compte bancaire.
has_other_cards	possède d'autres cartes bancaires.
proposed_credit_limit	score de risque de crédit (plus haut = plus fiable).
foreign_request	1 si demande faite depuis l'étranger
source	canal utilisé (INTERNET, téléphone, agence).

Tableau 3 : Description des Variables de 3 ème catégorie

Enfin, 6 variables techniques liées à la session ou au device utilisé :

Variable	Description
session_length_in_minutes	durée de la session web.
device_os	système d'exploitation utilisé (Windows, Android, etc.).
keep_alive_session	indicateur de session persistante.
device_distinct_emails_8w	nombre d'emails différents utilisés sur le même appareil en 8 semaines.
device_fraud_count	nombre de fraudes associées à l'appareil.
month	mois de la demande (de 0 à 7).

Tableau 4 : Description des Variables de 4 ème catégorie

4. Conclusion

Ce chapitre a permis de bien cerner la problématique de la détection de fraudes, en analysant les enjeux métier, les objectifs du projet, ainsi que la nature des données disponibles. Une compréhension approfondie du contexte et des variables manipulées constitue une base solide pour la suite du travail. Dans le chapitre suivant, nous procéderons à **l'exploration et à la préparation des données**, étapes essentielles pour garantir la qualité des analyses et la performance des modèles à venir.

Chapitre III :

Exploration et Préparation des Données

1. Introduction

L'objectif de cette étape est de mieux connaître les données en notre possession, et de les rendre exploitables pour la phase de modélisation. Pour cela, nous commençons par importer notre base de données, puis nous effectuons une première analyse descriptive via de la statistique et des visualisations afin d'identifier la qualité de nos variables et de vérifier la répartition de notre variable à prédire. Nous poursuivons avec du prétraitement des données, analysant et transformant les caractéristiques de notre base : normalisation, encodage des variables catégorielles, sélection des variables les plus adaptées à notre problématique... Notre sélection de variables s'appuie à la fois sur des critères statistiques et des critères métier. Ainsi, cette étape nous permet d'arriver à une base propre et exploitable pour la suite du projet.

2. Exploration des données

Avant de construire un modèle, il est important de s'intéresser aux données à notre disposition. En analysant un peu le jeu de données, on peut comprendre sa structure, repérer les types de variables qui le composent, trouver des valeurs manquantes ou aberrantes, observer la distribution des données, notamment celle de la variable cible. Cette analyse est la première étape pour pouvoir préparer les données correctement pour la suite du projet.

	income	name_email_similarity	prev_address_months_count	current_address_months_count	customer_age	days_since_request	intended_balcon_amount
count	1000000.000000	1000000.000000	1000000.000000	1000000.000000	1000000.000000	1.000000e+06	1000000.000000
mean	620.532550	0.493694	16.718568	86.587867	33.689080	1.025705e+00	8.661499
std	326.635426	0.289125	44.046230	88.406599	12.025799	5.381835e+00	20.236155
min	100.000000	0.000001	-1.000000	-1.000000	10.000000	4.036860e-09	-15.530555
25%	325.000000	0.225216	-1.000000	19.000000	20.000000	7.193246e-03	-1.181488
50%	662.500000	0.492153	-1.000000	52.000000	30.000000	1.517574e-02	-0.830507
75%	887.500000	0.755567	12.000000	130.000000	40.000000	2.633069e-02	4.984176
max	1000.000000	0.999999	383.000000	428.000000	90.000000	7.845690e+01	112.956928

Figure 6 : Statistiques descriptives des variables numériques

La **figure 6** présente les statistiques descriptives des principales variables numériques du jeu de données. On y retrouve pour chaque variable le nombre total d'observations (count), la moyenne (mean), l'écart-type (std), les valeurs minimales (min) et maximales (max), ainsi que les quartiles (25 %, 50 % ou médiane, et 75 %).

On note par exemple que la variable income varie entre 100 et 1000, avec une moyenne d'environ 620. Certaines variables comme prev_address_months_count current_address_months_count présentent des valeurs anormales telles que -1, ce qui peut indiquer des **valeurs manquantes codées** ou des erreurs à corriger lors du prétraitement.

Statistiques pour la variable 'payment_type':		Statistiques pour la variable 'employment_status':	
Nombre d'occurrences		Nombre d'occurrences	
payment_type		employment_status	
AB	370554	CA	730252
AA	258249	CB	138288
AC	252071	CF	44034
AD	118837	CC	37758
AE	289	CD	26522
		CE	22693
		CG	453

Figure 7 : Répartition des modalités des variables catégorielles

Pour mieux comprendre la structure des données qualitatives, la **Figure 7** joue un rôle essentiel dans la détection des déséquilibres.

Prenant en exemple la variable payment_type, la modalité "AB" est la plus dominante, suivie de "AA" et "AC", tandis que "AE" est très rare. Pour la variable employment_status, la catégorie "CA" est fortement majoritaire avec plus de 730 000 enregistrements. Ces constats mettent en lumière un déséquilibre important dans certaines catégories.




Figure 8 : Distribution de la variable cible

La **Figure 8** représente les deux classes que contient la base de données, qui indique si une opération est frauduleuse (**1**) ou non (**0**). On observe un fort déséquilibre entre les deux, ce qui peut poser problème pour l'entraînement de certains modèles de machine Learning.




Figure 9 : Carte de chaleur des corrélations entre les variables

La **Figure 9** représente cette matrice où chaque indice de corrélation calculé entre deux indicateurs x et y prend la valeur [-1, +1] qui représente la significativité de l'indice x par rapport à l'indice y est lorsque le coefficient se rapproche de 1 ou de -1 (marron foncé ou bleu foncé respectivement), ce qui indique une forte corrélation entre les deux indicateurs x et y, mais quand la valeur approche de 0, cela signifie une faible corrélation entre les deux indicateurs. La **Figure 10** est un nuage de points (scatter plot) qui explore la relation entre deux variables continues, Les points représentent des individus ou des observations, où chaque combinaison revenu/limite de crédit est affichée. Ce type de visualisation est utile pour identifier des motifs initiaux ou des valeurs aberrantes (outliers) avant une modélisation plus approfondie.




Figure 10 : Nuage de points

3. Préparation des données

Après avoir collecté les données brutes, il faut les préparer afin qu'elles soient exploitables et de qualité. Si ce n'est pas le cas, cela peut biaiser les analyses, conduire à des erreurs ou encore nuire aux performances des algorithmes d'apprentissage. Dans le cadre de ce projet, le prétraitement a été nécessaire afin de pouvoir s'appuyer sur des données fiables et exploitables. Il s'est traduit par plusieurs actions telles que la préparation des données pour nettoyer ces dernières (gestion des données manquantes, aberrantes, etc.), il faut aussi passer par normalisation et standardisation des données, parce que avec les données d'échelles variables peut constituer un problème dans l'analyse en ce sens qu'une variable numérique comme l'âge entre 29 et 77 sera plus pesante dans l'analyse qu'une variable dont les valeurs sont comprises entre 0 et 1 ce qui causerait un problème de biais par la suite, et très souvent, nous devons travailler à partir de données numériques, et ces données sont rarement comparables à l'état brut. La transformation des types de données en encodant les variables catégorielles et la réduction de la dimension en sélectionnant un nombre limité et pertinent de variables explicatives pour simplifier le problème et conduire à des modèles plus performants.

3.1 Nettoyage des données

Plusieurs opérations ont été réalisées pour corriger les incohérences présentes dans les données. Tout d'abord, un processus de détection des valeurs aberrantes a été mené, où les valeurs anormales ont été remplacées par des valeurs manquantes (**NaN**). Cela inclut notamment les colonnes booléennes contenant des valeurs autres que **0** ou **1**, les valeurs négatives dans des colonnes censées représenter des montants positifs comme **intended_balcon_amount**. Après l'application de la méthode "l'écart interquartile (**IQR**) " des valeurs aberrantes ont été détectées Comme indiqué dans **Figure 11** Les variables comme velocity_6h, velocity_24h, velocity_4w, intended_balcon_amount ont beaucoup de points éloignés des moustaches du box plot — ce sont des **outliers**, et nous avons décidé de conserver ces valeurs au lieu de les supprimer.




Figure 11 : Distribution des variables numériques

Ensuite, les valeurs manquantes comme la **Figure 12** présenter ont été traitées selon le type de variable pour les colonnes **numériques**, elles ont été remplacées par la **médiane** afin de préserver la distribution des données sans être influencées par les valeurs extrêmes ; pour les colonnes **booléennes**, elles ont été comblées par la valeur la plus **fréquente** (mode),

ce qui permet de maintenir la logique binaire. Ces opérations ont permis d'obtenir un jeu de données plus propre, cohérent et prêt pour l'étape de modélisation.

3.2 Rééquilibrage des classes

Dans de nombreux cas de détection de fraude bancaire, la variable cible est fortement déséquilibrée, les transactions normales sont largement majoritaires. Dans notre jeu de données initial presque **99 %** par rapport aux transactions frauduleuses qui sont très minoritaires.




Figure 12 : la répartition des valeurs manquantes dans chaque colonne

Ce déséquilibre peut fortement biaiser les algorithmes de classification, car ces derniers ont tendance à prédire majoritairement la classe majoritaire.

Pour pallier ce problème, nous avons utilisé la méthode **SMOTE** (*Synthetic Minority Over-sampling Technique*). Il s'agit d'une technique de sur échantillonnage qui génère des exemples synthétiques basés sur les vrais points de la classe minoritaire.

La méthode repose sur le principe suivant :

1. Prendre une vraie observation minoritaire
2. Trouver ses voisins proches (souvent 5)
3. Créer un nouveau point synthétique

Une fois le rééchantillonnage appliqué, la distribution de la variable cible devient plus homogène, ce qui améliore la capacité des modèles d'apprentissage à bien détecter les cas de fraude.

3.3 Encodage des Variables Catégorielles

Dans le cadre du prétraitement des données, les variables catégorielles doivent être converties en une forme numérique pour pouvoir être exploitées par les algorithmes de classification. Pour cela, nous avons appliqué la méthode du **One-Hot Encoding**, qui consiste à transformer chaque modalité d'une variable catégorielle en une colonne binaire (valeurs 0 ou 1). Par exemple, la variable **payment_type**, qui contient cinq modalités telles que **AB, AC, etc.**, a été convertie en cinq colonnes distinctes, on obtient la structure qui apparait dans la **Figure 13** avec 48 colonnes (on affiche le sommet de l'ensemble de donnée). Cette approche permet préserver la nature qualitative de ces variables, tout en les rendant exploitables par les modèles d'apprentissage automatique.

	fraud_bool	income	name_email_similarity	...	device_os_other	device_os_windows	device_os_x11
0	0	325	0	...	0	0	0
1	0	887	0	...	1	0	0
2	0	887	0	...	0	1	0
3	0	662	0	...	0	0	0
4	0	1000	0	...	1	0	0

5 rows × 48 columns

Figure 13 : Conversion des variables

3.4 Construire des données

Construire des données consiste à créer de nouvelles variables à partir des données existantes afin d'améliorer la performance des modèles prédictifs. Dans cette partie, plusieurs variables dérivées ont été construites pour enrichir l'information disponible comme la **Figure 14** montre la structure de l'ensemble de données globale avec 51 colonnes.

- ✓ « **Avg_months_per_address** » Cette variable mesure la stabilité résidentielle du client, selon la formule suivante :

$$\text{avg_months_per_address} = \frac{\text{prev_address_months_count} + \text{current_address_months_count}}{(\text{customer_age} \times 12) + 1}$$

- ✓ « **Credit_limit_to_income_ratio** » Cette variable évalue la pression du crédit proposé par rapport aux revenus du client, selon la formule suivante :
- ✓ « **Activity_per_minute** » Cette variable mesure l'intensité de l'activité du client pendant sa session, selon la formule suivante :

	income	name_email_similarity	prev_address_months_count	...	avg_months_per_address	credit_limit_to_income_ratio	activity_per_minute
0	325	0	31.0	...	0.116424	4.601227	1232.117647
1	887	0	31.0	...	0.497925	1.689189	3742.000000
2	887	0	9.0	...	0.047817	0.225225	432.260870
3	662	0	11.0	...	0.069252	0.301659	1324.125000
4	1000	0	31.0	...	0.124740	0.199800	3181.250000

5 rows × 51 columns

Figure 14 : La structure de l'ensemble de données

3.5 Standardisation des données

La standardisation est une autre technique de mise à l'échelle où les valeurs sont centrées autour de la moyenne avec un écart type unitaire. Cette transformation permet d'uniformiser l'échelle des variables numériques, de manière à ce qu'aucune ne domine les autres dans le processus d'apprentissage, comme le montre la **Figure 15** (le sommet de l'ensemble de donnée). Où certaines variables comme le revenu ou la limite de crédit peuvent avoir des valeurs très différentes en échelle.

Et sa formule s'écrit comme ci-dessous :

Où :

$$Z = \frac{X - \mu}{\sigma}$$

- **X** représente la valeur initiale,
- **μ** est la moyenne des valeurs de la variable,
- **σ** est l'écart-type

Si on l'applique, par exemple, à la variable **income**, on trouve :

Exemple : - income = 1000

- μ = 620

- σ = 326

Alors,
$$Z = \frac{1000 - 620}{326} = \frac{380}{326} \approx 1.17$$

	income	name_email_similarity	prev_address_months_count	...	avg_months_per_address	credit_limit_to_income_ratio	activity_per_minute
0	-1.200323	0.0	-0.167803	...	0.116424	4.601227	1232.117647
1	0.615125	0.0	-0.167803	...	0.497925	1.689189	3742.000000
2	0.615125	0.0	-0.903329	...	0.047817	0.225225	432.260870
3	-0.111700	0.0	-0.836463	...	0.069252	0.301659	1324.125000
4	0.980153	0.0	-0.167803	...	0.124740	0.199800	3181.250000

5 rows × 51 columns

Figure 15 : Standardisation des caractéristiques

3.6 Sélection des features Pertinentes

La Sélection des bonnes variables est cruciale pour construire des modèles de classification performants, de réduire la complexité computationnelle et d'éviter le sur apprentissage. Il est essentiel de sélectionner les variables les plus pertinentes.

Pour cela nous avons utilisé la matrice de corrélation qui apparait dans la **Figure 9** afin d'évaluer la relation entre chaque variable explicative et la variable cible (**fraud_bool**). Un seuil minimal de corrélation **0.2** a été fixé pour identifier les variables peu corrélées. Celles dont la corrélation absolue avec la variable cible était inférieure à ce seuil ont été considérées comme candidates à l'élimination.

Cependant, nous n'avons pas fondé nos décisions uniquement sur des critères **statistiques** : la pertinence métier a également été prise en compte, notamment pour les variables dont l'importance pourrait ne pas se refléter uniquement dans une relation linéaire simple. En effet, certaines relations complexes ou non linéaires peuvent être invisibles à travers la simple corrélation.

Cette étape de sélection permet ainsi de conserver un sous-ensemble de variables à la fois statistiquement **informatives** et conceptuellement **pertinentes**.

3.6 Extraction des caractéristiques avec l'ACP

L'extraction des caractéristiques fait partie du processus de prétraitement de données est une forme particulière de réduction de dimension, elle simplifie le coût des ressources nécessaires pour décrire précisément un ensemble de données important, parce que l'analyse des données complexe nécessite une grande utilisation de la mémoire et de traitement ou des algorithmes de classification qui nécessitent un seuil d'ajustement élevé avec les échantillons à tester, donc le résultat de cette étape est de déterminer un sous-ensemble des caractéristiques initiales est appelé caractéristiques extraites, ses caractéristiques-là, devraient contenir les informations pertinentes issues des données d'entrée, de sorte que la méthode ou l'algorithme à appliquer puisse être effectuée en utilisant cette représentation réduite au lieu des données initiales complètes. Et parmi les méthodes d'extraction des caractéristiques nous choisissons l'ACP (Analyse en Composantes Principales).

Remarque :

Il y a une différence entre l'extraction et la sélection, car l'extraction signifie l'obtention des nouvelles caractéristiques utiles à partir de caractéristiques existantes, alors que la sélection signifie choisir d'un sous-ensemble du groupe de caractéristiques d'origine, comme expliqué dans la **Figure 16**.




Figure 16 : Différence entre sélection et extraction

3.6.1 Processus de l'ACP

Il faut toujours standardiser les variables numériques avant l'ACP, sauf si elles sont déjà sous forme de taux, proportions ou indices comparables. Pour garantir des résultats justes et fiables de l'ACP les variables ont été standardisées, donc on va directement commencer à :

1. **Calcul de la matrice de covariance** avec la formule suivante :

$$\text{Cov}(X_j, X_{j'}) = \frac{1}{n} \sum_{i=1}^n (X_{ij} - \bar{X}_j)(X_{ij'} - \bar{X}_{j'})$$

2. **Calculer la corrélation linéaire** avec la formule suivante :

$$\rho(X_j, X_{j'}) = \frac{\text{Cov}(X_j, X_{j'})}{\sigma_j \cdot \sigma_{j'}}$$

✓ si les variables ne sont pas standardisées

3. **Calculer les valeurs et les vecteurs propres**

λ est dite valeur propre de la matrice A s'il existe un vecteur non nul $X \in K^n$ tel que : $A \cdot v = \lambda \cdot v$

Ou k sera $\mathbb{R}$ ou $\mathbb{C}$ et A est une matrice carrée de taille $n * n$ Le vecteur V est alors appelé vecteur propre de A associé à la valeur propre λ Et à partir de ça et de la matrice de corrélation linéaire qu'on a eue plus tôt, on peut calculer les valeurs propres, et puis on calcul des vecteurs propres associés aux valeurs.

4. **Choix du nombre de composantes principales à retenir**

Et cette action est très importante car elle déterminera la validité des indicateurs ce qui déterminent l'exactitude des résultats de notre système proposé.

5. Projection des données dans le nouvel espace réduit

Les données d'origine sont projetées sur les **k** composantes principales, **selon** la formule suivant :

$$Z = X \cdot V$$

- X : données standardisées
- Z : données projetées (PC1, PC2, ..., PCk)
- V : matrice des k vecteurs propres

3.6.2 Résultats expérimentaux

Nous avons appliqué l'ACP pour extraire les caractéristiques les plus pertinents, et nous avons réduit la dimension de 51 variables à seulement 12 variables, ce qui est inférieur au nombre initial de variables, comme **la Figure 17** montre. Après cette réduction dimensionnelle, on aura économisé le temps et la mémoire nécessaires à l'exécution du programme.

	PC1	PC2	PC3	...	PC10	PC11	fraud_bool
0	-912.343167	3.577949	-1.885135	...	0.464264	-1.691152	0
1	1597.539276	0.467729	-0.988757	...	-0.000168	0.817829	0
2	-1712.200674	-1.672850	-1.122117	...	2.466278	-0.314867	0
3	-820.335526	-1.363154	-2.737481	...	0.409968	-0.755120	0
4	1036.789083	-1.684357	-0.684884	...	0.273403	-1.721287	0
...	...	...	...	...	...	...	...
1977937	353.788838	0.404788	1.246452	...	0.000270	-0.303771	1
1977938	1062.539026	-1.186545	0.115906	...	-0.364945	-0.702299	1
1977939	-1485.925451	-1.392212	-1.596784	...	1.182874	2.190122	1
1977940	139.538729	0.530789	1.261303	...	1.540075	0.649967	1
1977941	-608.711152	1.017254	1.131068	...	-0.321384	-0.472718	1

1977942 rows × 12 columns

Figure 17 : Les caractéristiques extraites

4. Conclusion

Ce chapitre a permis d'explorer en profondeur les données disponibles, d'identifier leurs caractéristiques, leurs déséquilibres et les éventuelles valeurs manquantes. Un ensemble de traitements de préparation a été mis en place afin d'optimiser la qualité des données et d'assurer une meilleure performance lors de l'apprentissage. Ces étapes sont essentielles pour garantir la fiabilité des résultats des modèles à venir. Dans le chapitre suivant, nous passerons à la modélisation et l'expérimentation, où nous testerons différents algorithmes d'apprentissage afin d'identifier le plus adapté à notre problématique.

Chapitre IV :

Modélisation

Et

experimentation

1. Introduction

L'objectif principal de la modélisation est de concevoir un système capable d'identifier automatiquement les transactions bancaires frauduleuses à partir de données historiques. Cette étape constitue le cœur du processus de détection de la fraude, car elle permet de transformer des données brutes en connaissances exploitables via des algorithmes d'apprentissage automatique.

Plus spécifiquement, la modélisation vise à :

- ✓ **Distinguer** les comportements normaux de ceux potentiellement frauduleux.
- ✓ **Minimiser** les faux positifs (transactions normales signalées à tort comme frauduleuses) et les faux négatifs (fraudes non détectées).
- ✓ **Automatiser** le processus de détection pour le rendre plus rapide et plus efficace que les méthodes manuelles traditionnelles.
- ✓ **Adapter** le modèle aux évolutions des techniques de fraude en s'appuyant sur des modèles flexibles et entraînaables continuellement.

Ce processus repose sur des données transactionnelles (montant, heure, localisation, etc.) enrichies éventuellement par des informations contextuelles (profil client, historique, fréquence des opérations...). La modélisation permet donc de mettre en place une base analytique robuste sur laquelle repose la prise de décision en matière de sécurité bancaire.

2. Utilité de la modélisation pour l'identification des fraudes

La modélisation joue un rôle fondamental dans la lutte contre la fraude bancaire, en particulier face à l'augmentation croissante des volumes de transactions et à la sophistication des techniques frauduleuses. Elle permet de dépasser les limites des méthodes classiques fondées sur des règles statiques et des contrôles manuels, souvent insuffisantes pour détecter des comportements anormaux complexes et en constante évolution.

L'intérêt majeur de la modélisation réside dans sa capacité à :

- ✓ **Analyser automatiquement de grands volumes de données** en temps réel.
- ✓ **Identifier des motifs cachés** ou des corrélations subtiles que l'humain ne peut pas toujours percevoir.
- ✓ **S'adapter dynamiquement** aux nouvelles formes de fraude grâce à l'apprentissage continu à partir de nouvelles données.
- ✓ **Réduire les coûts opérationnels** liés à la surveillance manuelle et aux enquêtes longues.
- ✓ **Améliorer la réactivité** en signalant rapidement les activités suspectes pour une prise de décision rapide.

3.Choix des Méthodes de Modélisation

3.1 Raisons du Choix Initial des Algorithmes

Dans le cadre de la détection des fraudes, le choix des algorithmes d'apprentissage supervisé repose sur plusieurs critères essentiels : la robustesse face aux données déséquilibrées, la capacité de généralisation, la performance sur des données complexes, et l'interprétabilité. Nous avons retenu trois modèles prometteurs à tester et comparer : **Random Forest**, **Réseaux de Neurones (ANN)**, et **XGBoost**.

3.1.1 Random Forest

Random Forest est un algorithme d'ensembliste basé sur des arbres de décision. Il a été choisi pour plusieurs raisons :

- ✓ **Robustesse aux données bruitées et non linéaires** : il est capable de modéliser des relations complexes entre variables sans avoir besoin de transformations lourdes.
- ✓ **Bonne performance sur des jeux de données déséquilibrés**, notamment grâce à l'agrégation de multiples arbres, ce qui réduit la variance.
- ✓ **Facilité d'interprétation** : il permet d'obtenir une importance des variables, utile pour expliquer le comportement du modèle aux décideurs.

3.1.2 Réseaux de Neurones Artificiels (ANN)

Les réseaux de neurones ont été sélectionnés pour leur capacité à apprendre des structures complexes dans les données :

- ✓ **Puissance de modélisation** : les ANN peuvent capturer des relations non linéaires et interactions subtiles entre les variables, souvent présentes dans les comportements frauduleux.
- ✓ **Capacité d'adaptation** : ils s'adaptent bien à de grands volumes de données et peuvent être étendus à des architectures plus complexes (comme les réseaux profonds).
- ✓ **Souplesse** : leur structure flexible permet d'intégrer divers types de données, y compris des données temporelles ou séquentielles si nécessaire.

3.1.3 XGBoost (Extreme Gradient Boosting)

XGBoost est un algorithme de boosting de gradient très performant et couramment utilisé dans les compétitions de machine learning. Il est inclus pour les raisons suivantes :

- ✓ **Très bonne performance prédictive** : il surpasse souvent d'autres modèles sur des problèmes complexes comme la fraude.
- ✓ **Efficacité et rapidité** : il est optimisé pour la vitesse et la performance mémoire, ce qui est avantageux pour des jeux de données volumineux.
- ✓ **Gestion du déséquilibre** : XGBoost intègre des paramètres comme `scale_pos_weight` qui permettent de mieux prendre en compte les classes minoritaires (fraudes).

3.2 Résultat des modèles Initial

Xgboost :

	precision	recall	f1-score	support
No Fraud	0.97	1.00	0.98	26630
Fraud	0.99	0.93	0.96	11518
accuracy			0.98	38148
macro avg	0.98	0.96	0.97	38148
weighted avg	0.98	0.98	0.97	38148

Figure 18 :XGBoost resultat

Réseaux de Neurones Artificiels (keras) :

	precision	recall	f1-score	support
No Fraud	0.95	0.98	0.96	26630
Fraud	0.97	0.90	0.93	11518
accuracy			0.96	38148
macro avg	0.96	0.94	0.95	38148
weighted avg	0.96	0.96	0.96	38148

Figure19: Réseaux de Neurones resultat

Random Forest :

	precision	recall	f1-score	support
No Fraud	0.93	0.96	0.94	26630
Fraud	0.95	0.88	0.91	11518
accuracy			0.94	38148
macro avg	0.94	0.92	0.93	38148
weighted avg	0.94	0.94	0.94	38148

Figure 20 :Random Forest resultat

3.3 Analyse Comparative entre les modèles

3.3.1 Analyse Comparative

XGBoost : affiche les meilleures performances globales. Il obtient la précision la plus élevée (0.99) pour la classe 'Fraud', ce qui signifie qu'il génère très peu de faux positifs (transactions légitimes classées comme frauduleuses). Son rappel pour la classe 'Fraud' (0.93) est également le plus élevé, indiquant qu'il identifie une plus grande proportion des fraudes réelles par rapport

aux autres modèles. Le F1-score pour la classe 'Fraud' (0.96) et l'exactitude globale (0.98) sont aussi les meilleurs.

Réseau de Neurones (RN) : Le réseau de neurones se positionne en deuxième place. Ses scores de précision (0.97), rappel (0.90) et F1-score (0.93) pour la classe 'Fraud' sont légèrement inférieurs à ceux de XGBoost, mais restent très bons. L'exactitude globale (0.96) est également solide.

Random Forest : Ce modèle présente les performances les plus faibles parmi les trois pour cette tâche spécifique, bien que ses résultats soient encore respectables. Il a la précision (0.95), le rappel (0.88) et le F1-score (0.91) les plus bas pour la classe 'Fraud', ainsi que l'exactitude globale la plus faible (0.94).

3.3.2 Importance des Métriques en Détection de Fraude :

Rappel (Recall) pour 'Fraud' : Souvent considéré comme crucial. Un rappel élevé signifie que le modèle manque peu de transactions frauduleuses. Manquer une fraude peut avoir des conséquences financières importantes.

Précision (Precision) pour 'Fraud' : Également important. Une précision élevée signifie que lorsque le modèle prédit une fraude, il a souvent raison. Une faible précision entraînerait un grand nombre de faux positifs, bloquant potentiellement des transactions légitimes et nuisant à l'expérience client.

F1-Score : C'est la moyenne harmonique de la précision et du rappel, offrant une mesure équilibrée des deux.

Exactitude (Accuracy) : Bien qu'utile, elle peut être trompeuse dans les jeux de données déséquilibrés (fréquents en détection de fraude, où les fraudes sont rares). Les métriques spécifiques à la classe 'Fraud' sont généralement plus informatives.

3.3.3 Choix du modèle final :

le modèle XGBoost est le candidat le plus prometteur pour une optimisation plus poussée.

Il surpasse les deux autres modèles sur toutes les métriques clés, en particulier celles relatives à l'identification correcte des fraudes (rappel et précision pour la classe 'Fraud'). Il offre le meilleur compromis entre la détection efficace des fraudes réelles et la minimisation des fausses alertes.

Bien que le Réseau de Neurones montre également de bonnes performances, l'avantage de XGBoost est notable. Le Random Forest, dans cette configuration, semble moins performant pour cette tâche spécifique.

Il est recommandé de concentrer les efforts d'optimisation (par exemple, réglage des hyperparamètres, ingénierie des caractéristiques) sur le modèle XGBoost pour améliorer encore ses capacités de détection de fraude.

4. Architecture et principe de fonctionnement du modèle XGBoost

4.1 Introduction

Dans le cadre de la détection des fraudes dans les transactions bancaires, il est essentiel de disposer d'un modèle capable de traiter efficacement des données complexes, souvent déséquilibrées, tout en garantissant une haute précision. Parmi les différents algorithmes testés, **XGBoost (Extreme Gradient Boosting)** s'est distingué par ses performances supérieures en termes de précision, de rappel et de robustesse.

XGBoost est un algorithme d'apprentissage supervisé basé sur le principe du **gradient boosting**, qui construit des ensembles d'arbres de décision de manière itérative afin de minimiser une fonction de perte. Grâce à son efficacité, sa rapidité d'exécution et ses mécanismes intégrés de régularisation, XGBoost est devenu un choix de référence dans de nombreuses applications industrielles, notamment dans les systèmes de détection de fraude.

4.1.1 Principe de base du Gradient Boosting :

Le **Gradient Boosting** est une technique d'ensemble utilisée pour améliorer la performance de modèles dits "faibles", comme des arbres de décision peu profonds (appelés

stumps). Le principe fondamental repose sur une **construction séquentielle de modèles**, où chaque nouveau modèle cherche à **corriger les erreurs** du modèle précédent.

4.1.2 Fonctionnement général :

Le processus de Gradient Boosting suit les étapes suivantes :

- ✓ **Initialisation** d'un modèle simple (souvent une prédiction constante ou un arbre de décision).
- ✓ **Calcul des résidus** : à chaque itération, on mesure les erreurs (écart entre la vraie valeur et la prédiction).
- ✓ **Apprentissage d'un nouveau modèle** sur ces résidus, en cherchant à minimiser une fonction de perte (souvent l'erreur quadratique pour la régression ou la log-loss pour la classification).
- ✓ **Mise à jour du modèle global** : les prédictions sont ajustées en ajoutant le nouveau modèle pondéré.
- ✓ **Répétition** du processus jusqu'à convergence ou jusqu'au nombre maximal d'itérations.

4.1.3 Avantages du Gradient Boosting :

- ✓ Permet de **réduire le biais et la variance** du modèle.
- ✓ S'adapte bien à des **relations complexes** et non linéaires.
- ✓ Très performant dans les compétitions de machine learning et en pratique.

4.1.4 Limites:

- ✓ Sensible au **surapprentissage** si le modèle n'est pas régularisé.
- ✓ Peut être lent à entraîner sans optimisation.

4.2 Architecture interne de XGBoost

L'efficacité de XGBoost repose sur une architecture bien pensée, combinant **arbres de décision optimisés**, **fonction objectif personnalisable**, et **gestion fine des erreurs**.

L'algorithme construit les arbres **de manière séquentielle**, où chaque nouvel arbre tente de corriger les erreurs cumulées des arbres précédents.

4.2.1 Fonction objectif de XGBoost :

La fonction objectif (ou *objective function*) que XGBoost cherche à minimiser est composée de deux éléments :

$$\mathcal{L}(\phi) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k)$$

- $l(y_i, \hat{y}_i)$: fonction de perte (log-loss pour la classification binaire, par exemple)
- $\Omega(f_k)$: terme de régularisation pour contrôler la complexité du modèle

Ce deuxième terme est ce qui distingue XGBoost d'autres implémentations de boosting : il **pénalise les arbres trop complexes**, évitant ainsi le surapprentissage.

4.2.2 Construction des arbres :

- ✓ XGBoost construit les arbres **de manière additive** : à chaque étape, un nouvel arbre est ajouté pour corriger les erreurs du modèle précédent.
- ✓ Contrairement à certains algorithmes qui arrêtent la croissance d'un arbre par profondeur, XGBoost utilise une méthode d'**élagage (pruning)** basée sur un **seuil de gain minimum**.
- ✓ Chaque feuille de l'arbre représente une prédiction, et non une décision.

4.2.3 Calcul du gain avec gradient et hessien :

Pour déterminer la meilleure séparation à chaque nœud, XGBoost utilise à la fois :

- ✓ Le **gradient** (première dérivée de la fonction de perte)
- ✓ Le **Hessien** (deuxième dérivée)

Ce calcul permet d'évaluer très précisément l'impact d'une coupure sur la qualité globale du modèle.

5. Gestion des données déséquilibrées et Paramètres principaux de XGBoost

L'un des défis majeurs dans la détection des fraudes est la **forte déséquilibration** des classes : les transactions frauduleuses représentent généralement une **infime minorité** comparée aux transactions légitimes. Un modèle non adapté aurait tendance à **privilégier la classe majoritaire**, rendant la détection de fraude peu efficace.

5.1 Gestion des données déséquilibrées

XGBoost offre plusieurs mécanismes pour gérer ce déséquilibre :

- ✓ **Pondération des classes avec scale_pos_weight**

Ce paramètre permet d'accorder **plus d'importance à la classe minoritaire** (la fraude). Il est généralement calculé comme :

$$\text{scale_pos_weight} = \frac{\text{nombre de classes négatives}}{\text{nombre de classes positives}}$$

- ✓ **Fonction de perte adaptée**

En classification binaire, la **log-loss** utilisée dans XGBoost est sensible au déséquilibre, mais combinée à la pondération, elle reste efficace.

5.2 Paramètres principaux du modèle XGBoost

Paramètre	Description
<code>n_estimators</code>	Nombre total d'arbres (itérations de boosting)
<code>learning_rate</code>	Taux d'apprentissage, détermine l'impact de chaque nouvel arbre
<code>max_depth</code>	Profondeur maximale des arbres (contrôle la complexité)
<code>subsample</code>	Proportion d'échantillons utilisée pour chaque arbre
<code>colsample_bytree</code>	Proportion de variables utilisées pour chaque arbre
<code>gamma</code>	Gain minimum requis pour effectuer une division
<code>reg_alpha / reg_lambda</code>	Paramètres de régularisation L1 et L2
<code>scale_pos_weight</code>	Poids donné à la classe minoritaire

6. Tuning des Hyperparamètres avec Grid Search

6.1 Introduction

L'efficacité d'un modèle d'apprentissage automatique dépend en grande partie du choix de ses hyperparamètres. Ces derniers, contrairement aux paramètres appris lors de l'entraînement, doivent être définis avant la phase d'apprentissage et peuvent fortement influencer la performance du modèle. Afin d'obtenir des résultats optimaux, il est donc nécessaire de rechercher une combinaison d'hyperparamètres adaptée au problème étudié.

Parmi les différentes méthodes d'optimisation, la **Grid Search** (recherche par grille) est une approche exhaustive qui consiste à explorer systématiquement un espace défini de valeurs pour chaque hyperparamètre, en évaluant la performance du modèle pour chaque combinaison possible. Bien que cette méthode puisse être coûteuse en temps de calcul, elle permet d'identifier la configuration la plus performante dans l'espace de recherche spécifié.

Dans cette partie, nous présentons le principe de la Grid Search, son implémentation dans le cadre de notre projet, ainsi que les résultats obtenus à travers cette optimisation.

6.2 Fonctionnement de la Méthode Grid Search :

Le fonctionnement se déroule généralement en plusieurs étapes :

✓ **Définition de la grille de recherche :**

L'utilisateur spécifie une liste de valeurs possibles pour chaque hyperparamètre. Par

exemple, pour un modèle **XGBoost**, cela peut inclure différentes valeurs pour les paramètres `n_estimators` (nombre d'arbres), `max_depth` (profondeur maximale des arbres) et `learning_rate` (taux d'apprentissage).

✓ **Génération des combinaisons :**

Grid Search construit toutes les combinaisons possibles de ces hyperparamètres. Si trois valeurs sont définies pour deux paramètres, cela donne $3 \times 3 = 9$ combinaisons.

✓ **Entraînement et validation croisée :**

Pour chaque combinaison, le modèle est entraîné et évalué à l'aide d'une **validation croisée** (souvent k-fold cross-validation). Cette étape permet de mesurer la performance moyenne du modèle tout en réduisant le risque de surapprentissage.

✓ **Sélection de la meilleure configuration :**

La combinaison d'hyperparamètres donnant la meilleure performance (selon un score choisi comme l'exactitude, le rappel, l'AUC, etc.) est retenue comme la configuration optimale.

✓ **Réentraînement final :**

Une fois les meilleurs hyperparamètres identifiés, le modèle est réentraîné sur l'ensemble des données d'entraînement avec cette configuration optimale.

6.3 l'Implémentation de Grid Search:

```
param_grid = {  
    'n_estimators': [100, 200],  
    'max_depth': [3, 5, 7],  
    'learning_rate': [0.01, 0.1, 0.2],  
    'subsample': [0.8, 1],  
    'colsample_bytree': [0.8, 1],  
    'scale_pos_weight': [1, 2, 5, 10] |
```

Figure 21 :la grille de recherche

Après l'exécution de Grid Search, les meilleurs hyperparamètres obtenus sont :

Meilleurs hyperparamètres : {'colsample_bytree': 0.8, 'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 100, 'scale_pos_weight': 10, 'subsample': 0.8}

Figure 22: la meilleure configuration

6.4 Performances du Modèle Après Grid Search

	precision	recall	f1-score	support
No Fraud	0.97	1.00	0.98	26630
Fraud	0.99	0.97	0.96	11518
accuracy			0.98	38148
macro avg	0.98	0.96	0.97	38148
weighted avg	0.98	0.98	0.97	38148

Figure 23 :Après le grille

	precision	recall	f1-score	support
No Fraud	0.97	1.00	0.98	26630
Fraud	0.99	0.93	0.96	11518
accuracy			0.98	38148
macro avg	0.98	0.96	0.97	38148
weighted avg	0.98	0.98	0.97	38148

Figure 24 :Avant le grille

6.5 interprétation comparative :

Après l’optimisation des hyperparamètres du modèle XGBoost à l’aide de la méthode Grid Search, une amélioration significative a été observée, notamment sur la détection des fraudes. Le rappel pour la classe "Fraud" est passé de 0.93 à 0.97, ce qui signifie que le modèle est devenu plus efficace pour identifier les cas de fraude, en réduisant les faux négatifs. Cette amélioration a été obtenue sans compromettre les autres performances : la précision reste très élevée à 0.99, le F1-score stable à 0.96, et l’accuracy globale maintenue à 0.98. Cette progression démontre l’impact positif de l’optimisation des hyperparamètres sur les classes minoritaires, qui sont souvent les plus critiques dans les systèmes de détection de fraude.




Figure 25 : analyse graphique de recall

7. Conclusion

Ce chapitre a permis de comparer plusieurs approches de modélisation afin d'identifier celle offrant les meilleurs résultats en termes de détection des fraudes. Après une phase d'expérimentation rigoureuse, le modèle **XGBoost** s'est distingué par sa performance et sa capacité à gérer efficacement les spécificités des données. Ainsi, ce choix marque l'aboutissement de la phase de modélisation. Dans le chapitre suivant, nous aborderons le **déploiement du modèle**, afin de l'intégrer dans un système opérationnel accessible aux utilisateurs.

Chapitre V :

Le déploiement du modèle

1. Introduction

Avec la croissance exponentielle des transactions financières numériques, les institutions bancaires sont de plus en plus confrontées à des risques de fraudes sophistiquées. Ces fraudes peuvent prendre plusieurs formes, telles que l'usurpation d'identité, les transactions non autorisées, le blanchiment d'argent ou encore l'utilisation abusive de cartes bancaires. La nature en temps réel de ces opérations, combinée à leur volume élevé, rend les systèmes traditionnels de détection de fraudes insuffisants et parfois inefficaces.

Dans ce contexte, le recours à des approches intelligentes basées sur la science des données, l'apprentissage automatique et les systèmes de détection automatisés devient indispensable. Ces outils permettent non seulement d'identifier des comportements anormaux en temps réel, mais aussi d'anticiper de nouvelles formes de fraudes grâce à la modélisation prédictive.

Le présent projet de fin d'études s'inscrit dans cette logique et vise à concevoir, entraîner et déployer un modèle de détection des fraudes bancaires, capable d'identifier de manière automatique les transactions suspectes tout en minimisant le taux de faux positifs. Le déploiement du modèle a pour objectif de faciliter son intégration dans un environnement bancaire réel ou simulé, en assurant une réponse rapide et adaptée aux menaces potentielles.

Plus spécifiquement, les objectifs du déploiement sont :

- ✓ Fournir un système opérationnel capable de traiter les transactions en temps quasi-réel.
- ✓ Intégrer le modèle dans une architecture technique sécurisée et scalable.
- ✓ Permettre la visualisation et l'analyse des alertes générées par le système.
- ✓ Proposer une interface utilisateur pour les analystes métier afin de valider ou invalider les fraudes détectées.
- ✓ Assurer une possibilité de mise à jour continue du modèle selon les nouvelles données

2. Architecture de déploiement

2.1 Vue d'ensemble de l'architecture

L'architecture de déploiement de notre système de détection des fraudes bancaires a été conçue selon une approche modulaire et évolutive, permettant une séparation claire des responsabilités entre les différents composants. Cette architecture s'articule autour de trois couches principales :

- ✓ **Couche de présentation** : Interface utilisateur web permettant aux analystes de sécurité d'interagir avec le système, de soumettre des transactions pour analyse et de visualiser les résultats de prédiction.
- ✓ **Couche applicative** : Cœur du système qui gère la logique métier, l'authentification des utilisateurs, le traitement des requêtes et la coordination entre l'interface utilisateur et le modèle de prédiction.
- ✓ **Couche de modèle** : Composant responsable du chargement du modèle de machine learning, du prétraitement des données d'entrée, de l'exécution des prédictions et du post-traitement des résultats.

Cette architecture en trois couches offre plusieurs avantages, notamment une maintenance simplifiée, une évolutivité accrue et la possibilité de mettre à jour chaque composant indépendamment des autres. Elle permet également d'isoler le modèle de machine learning des autres parties du système, facilitant ainsi son remplacement ou sa mise à jour sans perturber l'ensemble de l'application.

2.2 Choix technologiques

Pour implémenter cette architecture, nous avons fait les choix technologiques suivants :



Langage de programmation : Python (version 3.11) a été sélectionné comme langage principal en raison de sa popularité dans le domaine du machine learning, sa riche écosystème de bibliothèques et sa facilité d'intégration avec divers frameworks web.



Framework web : Flask a été choisi comme framework web pour plusieurs raisons :

- ✓ Légèreté et flexibilité permettant une personnalisation adaptée à nos besoins spécifiques
- ✓ Courbe d'apprentissage rapide facilitant la maintenance par différentes équipes
- ✓ Excellente intégration avec les bibliothèques de machine learning Python
- ✓ Support robuste pour la création d'API RESTful
- ✓ Extensibilité via de nombreuses extensions (Flask-Login pour l'authentification, etc.)



Bibliothèques de machine learning :

- ✓ Scikit-learn pour l'implémentation des algorithmes de détection de fraudes
- ✓ Pandas et NumPy pour la manipulation et le prétraitement des données



Interface utilisateur :

- ✓ HTML5, CSS3 et Bootstrap pour une interface responsive et moderne
- ✓ JavaScript pour les interactions côté client et les visualisations dynamiques

2.3 Diagramme d'architecture du système




Figure 26 : l'architecture de système

Ce diagramme illustre clairement les différentes couches de l'architecture :

Couche Client : Le navigateur web de l'utilisateur

Couche Serveur Web : Nginx/Apache qui gère les requêtes HTTP

Couche Application : L'application Flask avec ses modules d'authentification, de routage et de présentation

Couche Modèle : Le cœur analytique avec prétraitement, modèle ML et post-traitement

Couche Stockage : Les fichiers pickle du modèle, les logs et la base de données optionnelle

2.4 Conception et Architecture Logicielle




Figure 27 : Diagramme de cas d'utilisation(Utilisateur)

L'utilisateur peut effectuer plusieurs actions :

- ✓ S'inscrire dans le système

- ✓ Se connecter
- ✓ Se déconnecter
- ✓ Consulter les informations sur la fraude
- ✓ Accéder au tableau de bord
- ✓ Effectuer une prédiction de fraude (transaction unique)
- ✓ Consulter l'historique des prédictions
- ✓ Consulter les détails d'une prédiction (cette action est incluse dans la consultation de l'historique des prédictions)




Figure 28 : Diagramme de cas d'utilisation(admin)

L'administrateur peut effectuer plusieurs actions :

- ✓ Se connecter au système
- ✓ Se déconnecter
- ✓ Accéder au tableau de bord
- ✓ Consulter les statistiques des utilisateurs
- ✓ Consulter l'historique global des prédictions

- ✓ Consulter les détails d'une prédiction (cette action est incluse dans la consultation de l'historique global des prédictions)




Figure 29 : Diagramme de composants

Structure générale

L'application est accessible via un **client web** (navigateur) qui interagit avec le **serveur Flask**, cœur de l'application, à travers des requêtes HTTP. Le serveur est chargé de gérer les différentes fonctionnalités telles que l'authentification, la prédiction, et l'interface utilisateur.

Composants principaux

Serveur Flask :

Joue le rôle de contrôleur central. Il :

- ✓ Utilise le **module de prédiction** pour appeler le modèle ML.
- ✓ Gère les **données utilisateur** (en mémoire).
- ✓ Rend les **templates HTML** pour l'interface web.
- ✓ Fait appel au **gestionnaire d'authentification** pour sécuriser l'accès.

Module de Prédiction :

Ce composant :

- ✓ Importe et utilise le **modèle ML** (mon_modele.pkl) pour effectuer des prédictions.
- ✓ Utilise également des **bibliothèques externes** (comme Pandas et Scikit-learn).

Gestionnaire d'Authentification :

Responsable de la gestion des sessions utilisateurs, de la connexion et de la vérification des identifiants.

Données Utilisateur (in-memory) :


Stockées temporairement pendant l'exécution, elles contiennent :

- ✓ Les comptes utilisateurs.
- ✓ Les **statistiques utilisateurs**.
- ✓ L'**historique des prédictions**.

Templates HTML :

Utilisés par le serveur Flask pour générer dynamiquement les pages web présentées à l'utilisateur.

2.5 Les interfaces Graphiques de projet



© 2025 Système de Détection de Fraudes Bancaires. Tous droits réservés.

Figure 30 : Page d'accueil




Figure 31 : Page de connexion


Détection des fraudes

CRÉER UN COMPTE

Nom d'utilisateur

Choisissez un nom d'utilisateur

Adresse e-mail

Entrez votre adresse e-mail

Mot de passe

Créez un mot de passe sécurisé


Confirmer le mot de passe

Confirmez votre mot de passe

☐ J'accepte les conditions d'utilisation

S'INSCRIRE

Déjà inscrit ? Connectez-vous ici



Activer Windows

Accédez aux paramètres pour activer Windows.

Figure 32 : Page d'inscription




Figure 33 : Tableau de bord

[Accueil](#)[Informations](#)[Tableau de bord](#)[Prédiction](#)[Déconnexion](#)

 **Détection des fraudes**

Prédiction de fraude

Remplissez le formulaire ci-dessous avec les informations de la transaction pour détecter une potentielle fraude.

Résultat de l'analyse

Prédiction: Fraude détectée

Probabilité de fraude: 66.09%

Attention! Cette transaction présente des signes de fraude. Nous recommandons une vérification supplémentaire.

Informations personnelles

Âge du client

Revenu (normalisé entre 0 et 1)

Similarité nom/email (entre 0 et 1)

Email gratuit

Informations de transaction

Montant de la transaction

Type de paiement

Jours depuis la demande

Limite de crédit proposée

Informations d'adresse

Mois à l'adresse précédente

Mois à l'adresse actuelle

Nombre de codes postaux (4 semaines)

Informations bancaires

Mois avec la banque

Nombre d'agences bancaires (8 semaines)


Possède d'autres cartes

[ANALYSER LA TRANSACTION](#)

© 2025 Système de Détection de Fraudes Bancaires. Tous droits réservés.

Figure 34 : Page de prediction

63 | Page



© 2025 Système de Détection de Fraudes Bancaires. Tous droits réservés.

Figure 35 : Page d'historique

3. Conclusion

En somme, ce chapitre a présenté l'ensemble des étapes techniques liées au déploiement du modèle, depuis son intégration dans une architecture fonctionnelle jusqu'à sa mise en ligne via des outils adaptés. Ce déploiement permet de rendre la solution accessible en temps réel aux utilisateurs finaux, tout en garantissant performance, sécurité et évolutivité. Dans le chapitre suivant, nous proposerons une conclusion générale du projet ainsi que quelques perspectives pour son amélioration et son extension future.

Chapitre VI:

Conclusion

Et

Perspective

Conclusion Générale

La détection des fraudes dans les transactions bancaires est un défi complexe et en constante évolution, exacerbé par la sophistication croissante des fraudeurs et le volume exponentiel des transactions numériques. Un projet visant à aborder ce problème doit impérativement adopter une approche multicouche, intégrant des techniques traditionnelles et des innovations technologiques de pointe. L'objectif principal est de minimiser les pertes financières pour les institutions bancaires et de protéger la confiance des clients, tout en assurant une expérience utilisateur fluide et sécurisée.

Historiquement, la détection des fraudes s'est appuyée sur des systèmes basés sur des règles prédéfinies. Bien que ces systèmes soient simples à mettre en œuvre et efficaces pour identifier des schémas de fraude connus, ils sont souvent rigides et génèrent un nombre élevé de faux positifs. De plus, ils peinent à s'adapter aux nouvelles typologies de fraude qui émergent constamment. Cette limitation souligne la nécessité d'aller au-delà des approches statiques.

L'avènement de l'analyse comportementale a marqué une avancée significative. En établissant des profils de comportement normaux pour chaque client et en signalant toute déviation, cette méthode permet de détecter des anomalies plus subtiles et des fraudes qui ne seraient pas capturées par des règles fixes. Cependant, la véritable révolution dans ce domaine est venue avec l'application de l'apprentissage automatique (Machine Learning) et de l'intelligence artificielle (IA).

Les algorithmes de Machine Learning, tels que les réseaux neuronaux, les arbres de décision et les machines à vecteurs de support, sont capables d'analyser d'énormes volumes de données transactionnelles pour identifier des modèles complexes et des corrélations qui échappent à l'analyse humaine. Ils peuvent être entraînés sur des ensembles de données historiques pour apprendre à distinguer les transactions légitimes des frauduleuses avec une précision remarquable. L'IA, et plus spécifiquement l'apprentissage profond, pousse cette capacité encore plus loin en permettant aux systèmes d'apprendre et de s'adapter de manière autonome, même face à des données non structurées et à des schémas de fraude inédits. Le traitement en temps réel, rendu possible par ces technologies, est crucial pour bloquer les transactions frauduleuses avant qu'elles ne soient finalisées, réduisant ainsi considérablement les pertes.

En outre, des techniques comme l'analyse de réseau sont essentielles pour identifier les groupes de fraudeurs et les schémas de fraude coordonnés en examinant les relations entre les entités. La biométrie, quant à elle, renforce l'authentification des utilisateurs, réduisant les risques liés à l'usurpation d'identité. Enfin, des technologies émergentes comme le Big Data, le Cloud Computing, la Blockchain

et l'Internet des Objets (IoT) offrent des opportunités supplémentaires pour améliorer la rapidité, la précision et la proactivité des systèmes de détection de fraude.

En somme, un projet de détection des fraudes réussi repose sur une synergie entre des méthodologies éprouvées et des innovations technologiques. Il ne s'agit pas seulement de détecter les fraudes, mais de le faire de manière efficace, en minimisant les faux positifs et en s'adaptant continuellement aux nouvelles menaces.

Perspectives

L'avenir de la détection des fraudes dans les transactions bancaires sera marqué par plusieurs tendances et développements clés :

✓ **La détection de la fraude en temps réel et prédictive:**

La capacité à détecter et à prévenir la fraude en temps réel deviendra la norme. Les systèmes évolueront vers des capacités prédictives, anticipant les fraudes potentielles avant même qu'elles ne se produisent, en identifiant les vulnérabilités et les indicateurs précoces. Cela nécessitera des infrastructures de traitement de données ultra-rapides et des algorithmes optimisés pour la performance en temps réel.

✓ **L'adaptation aux nouvelles technologies de paiement :**

Avec l'émergence de nouvelles technologies de paiement (paiements instantanés, monnaies numériques de banque centrale, DeFi), les systèmes de détection de fraude devront s'adapter rapidement. Chaque nouvelle technologie introduit de nouvelles vulnérabilités et opportunités pour les fraudeurs. Les projets futurs devront intégrer des capacités de surveillance et d'analyse spécifiques à ces nouveaux écosystèmes

✓ **L'importance de l'expérience client et de l'équilibre sécurité/commodité :**

Alors que la sécurité est primordiale, les solutions de détection de fraude devront trouver un équilibre délicat avec la commodité pour le client. Des processus de sécurité trop intrusifs peuvent nuire à l'expérience utilisateur et entraîner une perte de clientèle. Les futurs projets devront se concentrer sur des solutions qui minimisent les frictions pour les transactions légitimes tout en maintenant un niveau de sécurité élevé.

En conclusion, la détection des fraudes est un domaine dynamique qui exige une innovation continue. Les projets futurs devront non seulement exploiter pleinement le potentiel de l'IA et de l'apprentissage automatique, mais aussi favoriser la collaboration, s'adapter aux nouvelles technologies de paiement et maintenir un équilibre optimal entre sécurité et expérience client. C'est par cette approche holistique que les institutions bancaires pourront efficacement protéger leurs actifs et la confiance de leurs clients dans un paysage financier en constante évolution.

Ressources Documentaires

Webographie (ressources en ligne) :

- ❖ **Scikit-learn** – Documentation officielle
Disponible sur : <https://scikit-learn.org>
- ❖ **XGBoost** – Documentation officielle
Disponible sur : <https://xgboost.readthedocs.io>
- ❖ **Kaggle** – Dataset “Credit Card Fraud Detection”
Disponible sur : <https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>
(consulté le 18 juin 2025)
- ❖ **Python** – Documentation officielle
Disponible sur : <https://docs.python.org/fr/3/>
- ❖ **Towards Data Science** – Articles et tutoriels ML
Disponible sur : <https://towardsdatascience.com>
- ❖ **Flask** – Documentation officielle
Disponible sur : <https://flask.palletsprojects.com>

Bibliographie (ouvrages et articles scientifiques) :

- ❖ Geron, A. (2022). *Apprentissage automatique avec Scikit-Learn, Keras et TensorFlow – Concepts, techniques et outils pour construire des systèmes intelligents*. Éditions O'Reilly.
- ❖ Raschka, S., & Mirjalili, V. (2020). *Python Machine Learning – Machine Learning and Deep Learning with Python, scikit-learn, and TensorFlow 2*. Packt Publishing.
- ❖ Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.
- ❖ Chollet, F. (2018). *Deep Learning avec Python*. Éditions Pearson.
- ❖ Han, J., Kamber, M., & Pei, J. (2011). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.